

Redumask* Optimization

Otimização de Datasets e Modelos de Redes Neurais via
Máscaras de Redução Espacial

Autor: André A. B. C. Marques

Orientador: Prof. Dr. Ademar Takeo

Instituição: PUC - Campinas

Contexto e Motivação

Desafios de Infraestrutura no mundo da IA:

Crescimento de Datasets:

- Aumento expressivo no volume e resolução de dados para treinos de IAs.
- Gargalo no armazenamento e distribuição desses dados.

Redundância Espacial das Imagens.

- Excesso de ruído nas imagens.
- Imagens muitas vezes compostas por fundos neutros/irrelevantes.
- Oportunidade de simplificação dos dados.

Propostas

Proposta Geral:

Desenvolvimento de um framework capaz de aprender uma máscara binária estática de redução espacial aplicada diretamente sobre o dataset.

Desenvolvimento em duas Hipóteses:

Hipótese 1 - Banda Larga e Armazenamento

- Ao filtrar os pixels “irrelevantes”, reduz-se a dimensionalidade das imagens.
- Permite compressões com base em seleção inteligente dos dados.
- Ou seja, a capacidade preditiva se mantém constante.

Hipótese 2 - Desempenho e Normalização Espacial

- A eliminação dos pixels “irrelevantes” reduz também a complexidade contextual da imagem.
- Nesse contexto, partimos da hipótese que uma imagem menos complexa se torna mais simples para treinar um modelo.
- Espera-se então um melhor desempenho de modelos menos robustos e menos overfitting.

Metodologia


Pipeline de treinamento:

Treinamos vários classificadores. Depois geramos de maneira inteligente as máscaras para cada modelo. Criamos a máscara consenso com todas as máscaras inteligentes geradas. Novamente retreinamos todos os classificadores com a Máscara Consenso e comparamos com o baseline;

Fases Metodológicas:

- **Baseline:** Treinamento dos Modelos Classificadores no Dataset Galaxy10 para estabelecer referência de Performance.
- **Intelligent Mask:** Treino conjunto do Classificador + Máscara de seleção de píxeis. A seleção da máscara é feita no processo auto-denominado de “Validação de Pareto” - Uma seleção manual onde a relação de pixeis selecionados x performance é agradável.
- **Consensus Mask:** Agregação das máscaras de todos os Classificadores em uma máscara mais generalizada.
- **Treinamento Final:** Treinamento de todos os classificadores utilizados no estudo com a Consensus Mask aplicada.

Metodologia



Módulos e Arquitetura

Treinamento:


Treinamento modular, utilizando um orquestrador que chama todas os pedaços de código necessários para cada etapa.

Modulos Criados:


- Orquestrador (StaticMaskTraining ou train_classifier)
- TrainingConfig (Hiperparâmetros de fácil acesso)
- SelectionMask - Modelo Tensor do Tamanho das imagens do dataset.
- ModelTester (Framework para testes)
- training_loop (Instanciador do treino)
- Modelos Classificadores (resnet, lenet, cnn, etc.)
- AnalysisNotebook
- ConsensusMaskGenerator (Gerador da máscara conglomerada)

Arquitetura


O treinamento do ConsensusMask depois é importado direto para o treinamento do classificador, dessa forma, bypassando todo o treino da máscara.




O orquestrador StaticMaskTraining que realiza a chamada para todas os módulos necessários para o treinamento



Necessita de interação do usuário



Usuário toma decisões



Não há necessidade de Interação

Resultados

Baseline vs. Máscaras Estáticas

Aqui vamos colocar as comparações entre os Modelos Classificadores Padrão e os mesmos classificadores ao gerarem máscaras estáticas inteligentes. Ou seja, é a relação entre: Perda de Informação vs. Performance.

Modelo	Cenário	Acurácia	F1-Score	Pixels Ativos	$\Delta\Delta$ Acurácia vs. Baseline
LeNet256	Baseline vs. Dinâmica	75.44% vs. 74.56%	73.62% vs. 71.64%	9,77%	−0.88%−0.88%
ResNet20	Baseline vs. Dinâmica	84.46% vs. 84.59%	83.26% vs. 82.49%	32,70%	13%
ResNet34	Baseline vs. Dinâmica	85.65% vs. 70.74%	84.06% vs. 68.07%	0,19%	−14.91%−14.91%
SimpleCNN	Baseline vs. Dinâmica	80.51% vs. 74.75%	78.36% vs. 70.89%	8,97%	−5.76%−5.76%

Resultados

Baseline vs. Máscaras Estáticas

Insights:

- Lenet256 e SimpleCNN conseguiram retirar mais de 90% da imagem com pequena redução da acurácia.
- O Resnet20, por outro lado, conseguiu retirar menos imagem, mas conseguiu nisso um melhor desempenho, com +0.13% de acurácia.
- A Resnet34, por outro lado, conseguiu uma redução enorme da mascara, com somente 0.19%, mas mesmo assim ainda manteve um resultado de 70+% de acurácia.

Somente com esses resultados, já estamos perto de confirmar a Hipótese 1, que somos capazes de reduzir a dimensionalidade dos dados, sem perder desempenho considerável.

Resultados

Baseline vs. Consensus Mask

Aqui vamos colocar as comparações entre os Modelos Classificadores Padrão e os mesmos classificadores com a aplicação da Consensus Masks. Ou seja, é a relação entre: Perda de Informação mais generalizada vs. Performance.

Modelo	Cenário	Acurácia	F1-Score	Pixels Ativos	$\Delta\Delta$ Acurácia vs. Baseline
LeNet256	Baseline vs. Consenso	75.44% vs. 74.81%	73.62% vs. 71.72%	10,11%	-0.63%-0.63%
ResNet20	Baseline vs. Consenso	84.46% vs. 82.27%	83.26% vs. 80.24%	10,11%	-2.19%-2.19%
ResNet34	Baseline vs. Consenso	85.65% vs. 85.59%	84.06% vs. 84.43%	10,11%	-6%
SimpleCNN	Baseline vs. Consenso	80.51% vs. 77.88%	78.36% vs. 74.96%	10,11%	-2.63%-2.63%

Resultados

Baseline vs. Consensus Masks

Insights:

- A máscara de consenso resgatou a ResNet34 do colapso de esparsorização, restaurando sua acurácia para 85.59% (queda irrisória de -0.06% – -0.06%) e superando a baseline original em macro F1-score (84.43% vs. 84.06%).
- Interseção Coletiva: A máscara unificada age como um filtro espacial robusto que retém apenas características fundamentais do objeto, mitigando o viés individual de cada rede.
- Ou seja, as informações são mais generalizadas, considerando o que todos os modelos concordam que são informações relevantes.

Com esses resultados, continuamos provando a Hipótese 1, todavia, de maneira mais robusta, com mais generalização entre os modelos e uma redução ainda maior dos dados.

Resultados

Máscara Estática vs. Consensus Mask

O foco da comparação aqui é para vermos as diferenças que a normalização/generalização dos dados nos retorna em níveis de performance.

Modelo	Acurácia (Dinâmica)	Acurácia (Consenso)	$\Delta\Delta$ Acurácia (Consenso - Dinâmica)	Comparativo de Pixels Ativos
LeNet256	74,56%	74,81%	0,25%	Equivalente (~9.7% vs. 10.1%)
ResNet20	84,59%	82,27%	-2,32%	3x mais compressão (32.7% vs. 10.1%)
ResNet34	70,74%	85,59%	14,85%	Recuperação de colapso (0.19% vs. 10.1%)
SimpleCNN	74,75%	77,88%	3,13%	Equivalente (~9.0% vs. 10.1%)

Resultados

Máscaras Estáticas vs. Consensus Masks


Insights:

- O LeNet256 e o SimpleCNN aprenderam filtros que eliminam mais de 90% da imagem original apresentando pequenas reduções de acurácia.
- Regularização de Performance: Ao eliminar 67.3% da imagem (ruído de fundo), a ResNet20 obteve um ganho de +0.13% de acurácia em relação à baseline.
- Colapso por Super Pruning: A ResNet34 esparsorizou excessivamente a máscara, mantendo apenas 0.19% de pixels ativos (descarte excessivo), o que colapsou seu desempenho (−14.91%−14.91%).

Provamos agora com base no comparativo entre a Máscara Estática e o Consensus Mask de maneira final a Hipótese 1.

Resultados

Visão Geral dos Resultados:



Resultados

LENET256

RESNET20


RESNET34

SIMPLECNNRGB


Baseline

Visão das Máscaras Geradas

Learnable Mask



Consensus Mask



Discussão

Variabilidade de Resultados e Robustez do Consenso

Inconstância do Desempenho Fino

- Variabilidade Inter-Testes: O ganho exato de acurácia com as máscaras apresenta inconstâncias entre ciclos diferentes de treinamento.
- Evidência Histórica: Em testes anteriores, a máscara superou a baseline em mais cenários. No teste atual, observamos oscilações pequenas com leves perdas de acurácia.

Robustez Estrutural da Proposta

- Estabilidade da Compressão: Independentemente das flutuações finas de precisão, a eficácia na economia de armazenamento e banda é garantida, reduzindo ~90% da dimensionalidade das entradas de forma confiável.
- Consistência do Consenso: O ganho de desempenho da Máscara de Consenso em comparação com as Máscaras Dinâmicas Individuais é altamente consistente e atua como um excelente amortecedor de colapsos.

Conclusão

Validação da Hipótese de Armazenamento/Banda Larga:

- Provada: É perfeitamente viável realizar a compressão espacial prévia do dataset, retraindo apenas 10.11% da imagem original com perdas de acurácia irrelevantes (ex: -0.06% -0.06% na ResNet34). Redução real de custos físicos e de largura de banda na rede.

Validação da Hipótese de Desempenho/Regularização

- Parcialmente Provada (Condicional): O uso da máscara de fato funciona como regularizador espacial e protege os modelos contra ruído de fundo (ganho de $+3.13\%$ no SimpleCNN e resgate da ResNet34), contudo exibe sensibilidade à inicialização estocástica das redes.

Próximos Passos

- Desenvolvimento de biblioteca ou API customizada de compressão pré-pipeline direto no DataLoader do PyTorch.
- Testes do framework em outros domínios de imagens médicas e de satélite.