

Relatório Científico e Técnico: Projetos e Resultados ReduMask

Documento de Apresentação de Resultados e Status do Projeto

Destinatário: Orientador / Banca Acadêmica

Projeto: Otimização de Datasets e Modelos via Máscaras de Redução Espacial Colaborativas (ReduMask)

Localização: `journal-docs/relatorio-orientador.md`

1. Visão Geral, Conceito e Hipóteses de Pesquisa

O projeto **ReduMask** aborda um dos principais gargalos no treinamento e implantação de redes neurais profundas em Visão Computacional: **a redundância espacial e o custo computacional de processamento de fundos irrelevantes em dados de alta dimensão.**

A abordagem propõe um módulo leve de **Máscara de Seleção Binária Aprendível** (*SelectionMask*) otimizada via **Straight-Through Estimator (STE)** em conjunto com o classificador de imagens, além de um protocolo de **Inteligência Coletiva por Votação Majoritária** (*Consensus Mask*).

```
graph TD
    A["Imagem de Entrada (256x256x3)"] --> B["SelectionMask / Consensus Mask (M)"]
    B --> C["Produto de Hadamard (X ■ M)"]
    C --> D["Classificador de Imagem (Backbone)"]
    D --> E["Loss Total (Classificação + λ · Esparsidade L1)"]
```

As Duas Hipóteses Científicas Fundamentais:

- Hipótese 1 — Compressão Espacial pré-DataLoader e Eficiência de Banda:**
- Premissa:* Granularidades de fundo em imagens (ex: espaço profundo no astronômico Galaxy10 ou pratos/mesas no Food-101) contêm redundância.
- Objetivo:* Aprender um filtro espacial estático que elimine entre 40% e 90% dos pixels periféricos antes da transmissão ou inferência, com perda marginal de acurácia.
- Hipótese 2 — Regularização Espacial e Herança de Conhecimento:**
- Premissa:* Ao "cegar" o modelo para ruídos de fundo, a máscara atua como um regularizador espacial robusto.
- Objetivo:* Mitigar a tendência ao *overfitting* em modelos profundos e permitir que modelos leves herdem o mapa de atenção espacial construído por redes mais complexas.

2. Arquitetura Lógica e Estrutura Técnica do Código

O repositório foi construído em **PyTorch** com modularidade e rastreabilidade total.

```
src/
■■■ models/
■ ■■■ SelectionMask.py      # Módulo da máscara treinável via STE
■ ■■■ LeNet256.py          # LeNet adaptada para 256x256
■ ■■■ ResNet20.py          # ResNet-20 para visão computacional
■ ■■■ ResNet34.py          # ResNet-34 profunda
■ ■■■ SimpleCNNRGB.py      # CNN leve de 3 camadas RGB
■■■ utils/
■ ■■■ TrainingConfig.py    # Gerenciamento central de hiperparâmetros (PyTorch DataLoader)
■ ■■■ DatasetsDict.py      # Carregador e transformador unificado (Galaxy10, Food-101, CIFAR-10)
■ ■■■ TotalLoss.py         # Loss = Loss_CE + λ · Mask_L1_Sparsity
■ ■■■ LambdaScheduler.py   # Scheduler adaptativo com paciência para o fator λ
■ ■■■ StaticMaskTraining.py # Loop de treino conjunto (Modelo + Máscara)
■■■ scripts/
■ ■■■ train_classifier.py   # Treinador flexível (Baseline ou Máscara Congelada)
■ ■■■ generate_consensus_mask.py # Agregador de votação majoritária (Consenso)
■ ■■■ extract_metrics.py    # Extrator automatizado de métricas em Markdown
■ ■■■ plot_training_log.py  # Gerador de gráficos de tradeoff (Loss vs. Esparsidade vs. Acc)
```

■ Formulação Matemática dos Módulos Principais

A. Straight-Through Estimator (STE) em `SelectionMask.py`

Como a função $\text{round}()$ possui derivada nula em quase toda parte, utiliza-se a aproximação de identidade no gradiente durante o *backward pass*:

$\text{Forward Pass: } M = \text{round}(\sigma(W)) \in \{0, 1\}^{C \times H \times W}$

$\text{Backward Pass (Gradiente): } \frac{\partial M}{\partial W} \approx \frac{\partial \sigma(W)}{\partial W}$

B. Função de Perda Total & λ -Scheduler

$\mathcal{L}_{\text{Total}} = \mathcal{L}_{\text{CrossEntropy}}(y, \hat{y}) + \lambda \cdot \frac{1}{C \cdot H \cdot W} \sum_{c,h,w} |M_{c,h,w}|$

O `LambdaScheduler` monitora a evolução da perda de classificação. Se a perda estagnar por `patience` épocas, o fator λ é multiplicado por `factor`, forçando o modelo a elevar a taxa de compressão espacial.

C. Algoritmo de Inteligência Coletiva (`generate_consensus_mask.py`)


- Extração e Binarização Individual:** Para os $N=4$ modelos (M_1, M_2, M_3, M_4), extrai-se a máscara aprendida na melhor época.
- Agregação por Média Element-wise:** $\bar{M} = \frac{1}{4} \sum_{i=1}^4 M_i$.
- Votação Majoritária (Limiar ≥ 0.5):**
 $M_{\text{consenso}} = \mathbb{1}(\bar{M} \geq 0.5)$
(Pixels selecionados por pelo menos 2 dos 4 modelos são preservados).
- Re-codificação de Logits Extremos:**

$$W_{\text{consenso}} = \begin{cases} +10.0 & \text{se } M_{\text{consenso}} = 1.0 \\ -10.0 & \text{se } M_{\text{consenso}} = 0.0 \end{cases}$$

$$\approx \begin{cases} \sigma(10.0) \approx 1.0 \\ \sigma(-10.0) \approx 0.0 \end{cases}$$

3. Metodologia Experimental & Regimes de Treinamento

A validação é realizada comparando **3 Regimes de Treinamento** sob **4 Arquiteturas Heterogêneas** (**LeNet256** , **ResNet20** , **ResNet34** , **SimpleCNNRGB**):



- 1. **Regime Baseline:** O classificador é treinado na imagem bruta sem qualquer alteração espacial.
- 2. **Regime Learnable Mask (Dinâmico):** Treinamento conjunto do classificador e da **SelectionMask** via STE e λ -scheduler adaptativo.
- 3. **Regime Consensus Mask:** O classificador é treinado do zero recebendo a máscara consensual fixada e congelada (**requires_grad = False**).

4. Resultados Consolidados

Os dados a seguir foram extraídos diretamente dos checkpoints via **extract_metrics.py** .

4.1 Dataset Galaxy10 (10 Classes Astronômicas — Imagens 256 ltimes 256)

Arquitetura	Regime de Treino	Época	Val Accuracy	Precision	Recall	Macro F1-Score	Pixels Ativos (%)	Δ Acc vs. Baseline
LeNet256	Baseline	168	75.44%	75.41%	72.79%	73.62%	100.00%	-
	Learnable Mask	164	74.56%	74.05%	71.52%	71.64%	9.77%	-0.88%
	Consensus Mask	192	74.81%	74.31%	70.89%	71.72%	10.11%	-0.63%
ResNet20	Baseline	184	84.46%	84.28%	82.60%	83.26%	100.00%	-
	Learnable Mask	159	84.59%	83.79%	81.66%	82.49%	32.70%	+0.13%
	Consensus Mask	168	82.27%	80.74%	80.24%	80.24%	10.11%	-2.19%
ResNet34	Baseline	72	85.65%	84.02%	84.38%	84.06%	100.00%	-
	Learnable Mask	223	70.74% (colapso)	69.88%	68.16%	68.07%	0.19%	-14.91%
	Consensus Mask	162	85.59%	85.19%	83.81%	84.43%	10.11%	-0.06%
SimpleCNNRGB	Baseline	190	80.51%	80.45%	77.42%	78.36%	100.00%	-

Arquitetura	Regime de Treino	Época	Val Accuracy	Precision	Recall	Macro F1-Score	Pixels Ativos (%)	\$\Delta\$ Acc vs. Baseline
	Learnable Mask	200	74.75%	73.78%	70.34%	70.89%	8.97%	-5.76%
	Consensus Mask	198	77.88%	78.40%	75.04%	74.96%	10.11%	-2.63%

4.2 Dataset Food-101 (101 Classes Complexas de Imagens Naturais — Imagens \$256 \times 256\$)

Arquitetura	Regime de Treino	Época	Val Accuracy	Precision	Recall	Macro F1-Score	Pixels Ativos (%)	\$\Delta\$ Acc vs. Baseline
LeNet256	Baseline	190	33.69%	35.03%	33.49%	33.14%	100.00%	-
	Learnable Mask	134	31.59%	32.71%	31.35%	30.54%	51.53%	-2.10%
	Consensus Mask	200	31.08%	33.02%	31.02%	30.28%	58.04%	-2.61%
ResNet20	Baseline	187	56.34%	59.03%	56.39%	56.40%	100.00%	-
	Learnable Mask	168	48.70%	52.75%	48.57%	48.70%	26.15%	-7.64%
	Consensus Mask	200	52.98%	55.71%	52.85%	52.32%	58.04%	-3.36%
ResNet34	Baseline	48	59.14%	59.05%	59.02%	58.82%	100.00%	-
	Learnable Mask	61	52.65%	55.08%	52.60%	52.39%	85.81%	-6.49%
	Consensus Mask	200	50.51%	50.23%	50.37%	49.95%	58.04%	-8.63%
SimpleCNNR34	Baseline	189	17.83%	16.41%	17.73%	16.53%	100.00%	-
	Learnable Mask	23	0.74% (<i>colapso</i>)	0.01%	0.99%	0.01%	0.00%	-17.09%
	Consensus Mask	200	14.72%	14.96%	14.66%	14.27%	58.04%	-3.11%

■ 5. Debates Científicos e Principais Achados

[!IMPORTANT]

1. Mecanismo Anti-Colapso por Inteligência Coletiva

Durante o treinamento dinâmico (\$STE\$), redes neurais expostas a gradientes de esparsidade podem sofrer colapso estocástico.

* Na **ResNet34 (Galaxy10)**, a máscara reduziu os pixels para **0.19%**, derrubando a acurácia para

70.74%.

* No **SimpleCNNRGB (Food-101)**, a máscara zerou completamente a entrada (**0.00% de pixels**), colapsando a acurácia para **0.74%**.

Resultado do Consenso: Em ambos os casos, a **Consensus Mask** extinguiu o colapso, restaurando a ResNet34 no Galaxy10 para **85.59%** (F1-Score de **84.43%**, superior aos 84.06% da baseline) e a SimpleCNN no Food-101 para **14.72%** (+13.98% de ganho).

[!TIP]

2. Herança de Conhecimento Espacial em Redes Leves

Redes de menor capacidade (**SimpleCNNRGB** e **ResNet20**) possuem dificuldade em aprender representações de atenção espacial dinamicamente. Quando treinadas com o consenso estático congelado construído com a colaboração das redes mais profundas:

* A **SimpleCNNRGB** no Galaxy10 ganhou **+3.13%** de acurácia vs sua própria máscara (77.88% vs 74.75%).

* A **ResNet20** no Food-101 ganhou **+4.28%** de acurácia vs sua própria máscara (52.98% vs 48.70%).

[!NOTE]

3. Adaptação Semântica Automática da Compressão por Domínio

O percentual de retenção de pixels da máscara de consenso adaptou-se automaticamente à natureza dos dados:

* **Galaxy10 (Dados Astronômicos):** Retenção de **10.11% dos pixels** (compressão de **89.89%**). O fundo estelar escuro foi massivamente descartado sem perda de acurácia.

* **Food-101 (Imagens Naturais Complexas):** Retenção de **58.04% dos pixels** (compressão de **41.96%**). Para discriminar 101 classes de alimentos, o consenso preservou o contorno do prato e elementos periféricos necessários à classificação.

■ 6. Próximos Passos e Roadmap de Publicação

1. **Validação no Dataset CIFAR-10 / CIFAKE:** Execução da suíte completa de automação em `run_all_cifar10.sh`.
2. **Estudo de Ablação da ResNet34:** Implementação da flag `--exclude resnet34` em `generate_consensus_mask.py` para avaliar a contribuição individual de redes profundas na formação do consenso.
3. **Explicabilidade com Grad-CAM (`evaluate_gradcam.py`):** Avaliação da sobreposição espacial (IoU / Pearson) entre os mapas de calor do Grad-CAM e a máscara de consenso binária.
4. **Redação do Artigo Científico:** Consolidação de figuras, tabelas e escrita em LaTeX para submissão à conferência/periódico (ex: JCNN / Neurocomputing).

Relatório gerado em Outubro/2026. Código e checkpoints disponíveis em `PowerRangersCode/`.